

传统机器学习方法在手写数字图像分类中的应用实验报告

一、实验目的

- 掌握传统机器学习方法处理图像分类任务的基本流程，包括数据加载、特征转换、模型训练与评估。
- 对比多种传统分类器（KNN、朴素贝叶斯、逻辑回归、SVM、决策树、随机森林）在手写数字识别任务上的表现差异。
- 理解原始像素作为特征的优缺点，以及不同模型的适用场景与局限性。
- 学会使用准确率、混淆矩阵和错误样本分析方法，对模型性能进行全面评估。

二、数据集说明

- 数据集名称：**Scikit-learn 自带的 digits 手写数字数据集
- 图像大小：**每张图像为 **8×8 像素** 的灰度图像
- 样本数量：**共 1797 张图像，其中 75% 为训练集，25% 为测试集
- 类别数量：**10 个类别，对应数字 0~9
- 图像如何表示为特征向量：**

将 8×8 的二维图像矩阵按行展开，转换为长度为 64 的一维向量，每个维度对应一个像素的灰度值，作为模型的输入特征。

三、实验方法


方法	简要说明
KNN (最近邻)	通过计算样本间的距离，选择最近的 K 个邻居投票确定类别
Naive Bayes (朴素贝叶斯)	基于贝叶斯定理，假设特征间相互独立，通过概率计算进行分类
Logistic Regression (逻辑回归)	通过线性模型拟合数据，输出样本属于各类别的概率

方法	简要说明
SVM（支持向量机）	寻找能最大化类别间隔的最优分类超平面，泛化能力强
Decision Tree（决策树）	根据特征阈值逐层划分数据，形成树状决策结构
Random Forest（随机森林）	集成多棵决策树，通过投票机制提升分类稳定性与准确率

四、实验结果

任务 1：数据准备

数据集中总图像数量：1797 张
单张图像的尺寸：28 × 28 像素
每张图像展开后的特征向量维度：784 维
数据集中的所有类别标签：[0 1 2 3 4 5 6 7 8 9]
每个类别对应的样本数量：
数字 0: 178 张
数字 1: 182 张
数字 2: 177 张
数字 3: 183 张
数字 4: 181 张
数字 5: 182 张
数字 6: 181 张
数字 7: 179 张
数字 8: 174 张
数字 9: 180 张



任务 2：数据划分

```
===== 数据集划分结果 =====  
总样本数量：1797  
训练集样本数量：1347  
测试集样本数量：450  
测试集比例：25.04%
```

训练集和测试集的作用

训练集 (Training Set)

占比：75% 左右

作用：用来训练机器学习模型，让模型学习手写数字的特征规律，建立分类规则。

测试集 (Test Set)

占比：25% 左右

作用：不参与训练，专门用来测试模型的泛化能力，评估模型在从未见过的新数据上的分类准确率。

任务 3：特征表示

```
omework7/exercise3.py
一张 8x8 原始图像（二维矩阵）：
[[ 0.  0.  5. 13.  9.  1.  0.  0.]
 [ 0.  0. 13. 15. 10. 15.  5.  0.]
 [ 0.  3. 15.  2.  0. 11.  8.  0.]
 [ 0.  4. 12.  0.  0.  8.  8.  0.]
 [ 0.  5.  8.  0.  0.  9.  8.  0.]
 [ 0.  4. 11.  0.  1. 12.  7.  0.]
 [ 0.  2. 14.  5. 10. 12.  0.  0.]
 [ 0.  0.  6. 13. 10.  0.  0.  0.]]
图像形状： (8, 8)

=====
转换后的 64 维特征向量（一维）：
[ 0.  0.  5. 13.  9.  1.  0.  0.  0.  0. 13. 15. 10. 15.  5.  0.  0.  3.
 15.  2.  0. 11.  8.  0.  0.  4. 12.  0.  0.  8.  8.  0.  0.  5.  8.  0.
  0.  9.  8.  0.  0.  4. 11.  0.  1. 12.  7.  0.  0.  2. 14.  5. 10. 12.
  0.  0.  0.  0.  6. 13. 10.  0.  0.  0.  0.]
向量形状： (64,)
```

1. 图像如何转换为特征向量

本次实验中，每张手写数字图像为 **8×8 像素的二维灰度矩阵**，转换为特征向量的方式为：

将 8×8 的二维矩阵按行（或列）顺序展开，拼接成一个长度为 64 的一维向量。

每个维度对应图像中一个像素的灰度值，取值范围为 0~16，以此作为模型的输入特征。

2. 为什么传统机器学习方法需要这种转换？

- 传统机器学习模型（如 KNN、SVM、逻辑回归等）的计算逻辑基于一维向量 / 矩阵运算，无法直接处理二维矩阵形式的图像数据。
- 特征向量可以将图像信息标准化为固定长度的数值序列，方便模型计算样本间的距离、概率或分类边界。
- 这种转换能将图像的像素信息映射到向量空间，让模型可以学习不同数字的像素分布模式。

3. 原始像素作为特征的优缺点

优点：

- 实现简单，无需复杂的特征工程，直接使用图像的原始信息。
- 对低分辨率、简单结构的图像（如手写数字）有较好的适配性。

局限：

- 缺乏对图像变换的鲁棒性，图像平移、旋转、缩放后，像素位置改变会导致模型识别错误。
- 特征维度随图像分辨率急剧增加，高分辨率图像会带来巨大的计算成本。
- 无法提取图像的语义信息（如边缘、形状），仅依赖像素的绝对位置和亮度，泛化能力有限。

任务 4：模型训练

传统机器学习分类器 测试集准确率对比	
KNN 最近邻	: 准确率 = 0.9933
朴素贝叶斯	: 准确率 = 0.8556
逻辑回归	: 准确率 = 0.9733
SVM 支持向量机	: 准确率 = 0.9867
决策树	: 准确率 = 0.8711
随机森林	: 准确率 = 0.9756

任务 5：结果比较

模型准确率表格：

模型	准确率
KNN 最近邻	0.9933
朴素贝叶斯	0.8556
逻辑回归	0.9733
SVM 支持向量机	0.9867
决策树	0.8711
随机森林	0.9756

准确率最高：KNN 模型。

准确率最低：朴素贝叶斯模型。

表现差异是否明显：

差异明显，KNN、SVM、随机森林、逻辑回归效果很好；决策树一般；朴素贝叶斯效果最差。


产生差异的原因

KNN、SVM 适合像素特征，能很好区分数字轮廓；随机森林集成多棵树，稳定性强；逻辑回归线性拟合能力够用；单棵决策树容易过拟合；朴素贝叶斯假设特征相互独立，但手写数字像素存在关联，不符合假设，所以效果最差。


任务 6：错误样本分析

KNN 模型混淆矩阵：

混淆矩阵显示，模型的预测结果绝大多数集中在对角线上，仅存在极少量误分类样本，整体准确率极高



错误分类样本：



哪些数字最容易被混淆

最容易混淆的数字是 5 和 9，其次是 9 和 4。

为什么会被误判

1. 8×8 图像分辨率低，笔画细节模糊，几个数字轮廓本身就很相似；
2. 部分手写数字书写不标准，形状更接近其他数字；
3. 模型只靠像素距离判断，不能理解数字结构，容易把轮廓相近的认错。

结果简要分析

- **模型表现差异明显：**KNN 和 SVM 的准确率超过 98%，在该任务中表现最优；朴素贝叶斯和决策树的准确率相对较低。
- **易混淆数字：**5 和 9、9 和 4 是最容易被模型误判的数字对，主要原因是这些数字在低分辨率下轮廓高度相似。
- **模型特性影响：**基于距离的模型（KNN、SVM）对像素级特征的适配性更好；而基于概率或单一决策树的模型（朴素贝叶斯、决策树）易受假设条件限制或过拟合影响，表现相对较差。

五、实验总结

1. 传统机器学习处理图像的基本流程

1. **数据准备：**加载数据集，划分训练集与测试集
2. **特征转换：**将二维图像展开为一维特征向量
3. **模型训练：**使用训练集数据拟合分类器
4. **模型评估：**在测试集上计算准确率，绘制混淆矩阵
5. **错误分析：**可视化错误样本，分析误判原因

2. 不同分类器的优缺点

表格

模型	优点	缺点
KNN	实现简单、效果优秀、无需训练	预测速度慢、对大数据集不友好
SVM	泛化能力强、对高维数据表现好	训练速度慢、调参复杂
逻辑回归	训练快、解释性强	仅能处理线性可分数据
决策树	训练快、无需特征缩放	易过拟合、稳定性差
随机森林	稳定性强、抗过拟合	模型复杂度高、可解释性差
朴素贝叶斯	训练速度极快	特征独立假设不成立时效果差

3. 使用原始像素作为特征的局限

- 特征维度高**：图像分辨率稍高时，向量长度会急剧增加，导致计算成本上升。
- 缺乏语义信息**：仅包含像素亮度，无法提取边缘、形状等高级特征。
- 对变化敏感**：对旋转、平移、缩放等图像变换缺乏鲁棒性。
- 泛化能力有限**：在手写数字这类简单任务上表现尚可，但在复杂自然图像任务中效果较差。

七、思考题

1. 为什么传统机器学习方法需要先把图像转换为特征向量？

传统机器学习模型（如 KNN、SVM、逻辑回归等）的输入要求是**一维向量**，无法直接处理二维图像矩阵。

- 图像是二维数据，而模型的计算逻辑基于向量 / 矩阵运算，必须转换为一维向量才能输入模型。
- 特征向量可以把图像的像素信息标准化为固定长度的数值序列，方便模型学习和比较样本间的相似性。

2. KNN、SVM、决策树和随机森林的分类思想有什么不同？

- KNN（最近邻）**：基于“物以类聚”的思想，通过计算新样本与训练集中样本的距离，选择最近的 K 个邻居，通过投票决定类别。

- **SVM（支持向量机）**：寻找一个最优的分类超平面，最大化不同类别样本之间的间隔，使分类边界具有最强的泛化能力。
 - **决策树**：通过一系列 “if-else” 规则，根据特征阈值逐层划分数据，形成树形的决策路径，最终确定样本类别。
 - **随机森林**：集成多棵决策树，通过随机选择样本和特征构建不同的树，再通过投票机制综合所有树的预测结果，得到最终分类。
-

3. 为什么单棵决策树容易过拟合？

- 单棵决策树在训练时会尽可能地划分数据，甚至会学习到训练集中的噪声和异常值，形成过于复杂的分支。
 - 这种 “死抠细节” 的学习方式会导致模型在训练集上表现极好，但对新数据的泛化能力很差，也就是过拟合。
-

4. 为什么随机森林通常比单棵决策树更稳定？

- 随机森林通过**多棵树集成**和**随机采样**（样本随机、特征随机），降低了单棵树对训练数据和噪声的依赖。
 - 不同的树学习到的是数据的不同侧面，投票机制会抵消单棵树的过拟合倾向，从而提升整体模型的稳定性和泛化能力。
-

5. 如果图像发生平移、旋转或缩放，直接使用原始像素作为特征会有什么问题？

- **像素位置会改变**：平移、旋转或缩放后，同一个数字的像素分布会发生变化，与训练集中的样本不再匹配。
- **模型无法识别变换后的数字**：基于像素距离的模型（如 KNN）会把这些变换后的数字当成完全不同的样本，导致分类错误。
- **泛化能力差**：原始像素特征不具备 “不变性”，无法理解数字的形状和结构，只能依赖像素的绝对位置。